



รายวิชา 568 351 สถิติและการประยุกต์ทางเภสัชศาสตร์

## สหสัมพันธ์เชิงเส้น (LINEAR CORRELATION)

รศ.ดร.ลาวัณย์ ศรีธธาพุท

ภาควิชาสารสนเทศศาสตร์ทางสุขภาพ คณะเภสัชศาสตร์ มหาวิทยาลัยศิลปากร

## References



- รศ.ศศิธร สุวัชรวิทยกิจ สถิติสำหรับวิทยาศาสตร์และนักวิทยาศาสตร์  
ประยุกต์ เล่ม 1, เล่ม 2 มหาวิทยาลัยศิลปากร
- Elementary Statistics: A Step by Step Approach, 8<sup>th</sup> edition,  
Allan G. Bluman ,McGraw-Hill, 2009.
- ผศ. ดร.ลาวัณย์ ศรีธธาพุท คู่มือการใช้ซอฟต์แวร์เสรีทางสถิติ PSPP  
สำหรับผู้เริ่มต้น, โรงพิมพ์มหาวิทยาลัยศิลปากร, 2012.

## ตัวแปร (Variable)



- ตัวแปร คือ คุณลักษณะ (characteristics) ใดๆ ของสิ่งที่สนใจศึกษา
- สิ่งที่น่าสนใจศึกษา = หน่วยตัวอย่าง
- เมื่อทำการวัดข้อมูลหน่วยตัวอย่างแต่ละหน่วยที่สนใจศึกษาซึ่งมี  
คุณลักษณะต่างกันไป ข้อมูลที่วัดได้จากหน่วยตัวอย่างเรียกว่า  
“ค่าตัวแปร”
- ตัวแปรถูกแบ่งตามลักษณะของค่าของตัวแปรเป็น 2 ประเภท คือ
  - ตัวแปรเชิงคุณลักษณะ (Qualitative Variable) คือ ตัวแปรที่บอกคุณลักษณะ  
ของการแบ่งกลุ่ม หรือของการจัดอันดับ - มีมาตรวัดเป็นชนิดนามบัญญัติ  
(nominal) หรือเป็นชนิดอันดับ (ordinal)
  - ตัวแปรเชิงปริมาณ (Quantitative Variable) คือ ตัวแปรที่มีค่าเป็นปริมาณซึ่ง  
สามารถวัดได้เป็นตัวเลข (ที่สามารถนำไปคำนวณได้) - มีมาตรวัดเป็นชนิด  
อันตรภาค (interval) หรือเป็นชนิดอัตราส่วน (ratio)

## ความสัมพันธ์เชิงเส้น(ตรง)



- ความสัมพันธ์เชิงเส้น (Linear Correlation) หมายถึง  
ความสัมพันธ์ของตัวแปรเป็นแบบเชิงเส้นตรง
- สัมประสิทธิ์สหสัมพันธ์เชิงเส้น (Linear Correlation  
Coefficient) หมายถึง ค่าที่ใช้วัดความสัมพันธ์เชิงเส้น
- หมายเหตุ: ความสัมพันธ์ของตัวแปรยังมีแบบอื่นๆอีก เช่น  
พาราโบลา เอ็กส์โปเนนท์เชียล

## สัมประสิทธิ์สหสัมพันธ์เชิงเส้น



- สัมประสิทธิ์สหสัมพันธ์เชิงเส้น (Linear Correlation Coefficient) เป็นค่าที่ใช้วัดองศาแห่งความสัมพันธ์เชิงเส้น (degree of linear relationship) ระหว่างตัวแปร 2 ตัว
- ใช้สัญลักษณ์ สำหรับประชากร  $\rho_{xy}$
- ใช้สัญลักษณ์ สำหรับตัวอย่างสุ่ม  $r_{xy}$
- สูตรที่ใช้หาสัมประสิทธิ์สหสัมพันธ์เชิงเส้นที่นิยมมากที่สุด คือ สูตรของ Pearson ที่เรียกว่า สหสัมพันธ์ของเพียร์สัน (Pearson's correlation, Pearson's product-moment coefficient)

## แนวคิดของ Pearson's Correlation



- Pearson (1930): แนวคิดของ Pearson's Correlation คือถ้าตัวแปร X มีความสัมพันธ์กับตัวแปร Y แล้วค่าของ X จะต้องเปลี่ยนไปตามค่า Y ซึ่งอาจเป็นไปได้ในทิศทางเดียวกันหรือตรงข้ามกันก็ได้ โดยใช้ค่าเฉลี่ยเป็นจุดเปรียบเทียบการเปลี่ยนไปของค่าตัวแปร
- ความสัมพันธ์เชิงเส้นระหว่างการเปลี่ยนแปลงของค่า X และ Y แทนด้วย  $(X_i - \bar{X})(Y_i - \bar{Y})$
- ทิศทางของความสัมพันธ์เชิงเส้นแสดงด้วยเครื่องหมายของ  $(X_i - \bar{X})(Y_i - \bar{Y})$

## สหสัมพันธ์ของเพียร์สัน



- สหสัมพันธ์ของเพียร์สัน (Pearson's correlation coefficient, Pearson's product-moment correlation coefficient) คือการนำค่าความแปรปรวนร่วมระหว่างตัวแปรสุ่มทั้งสองมาหารด้วยค่าส่วนเบี่ยงเบนมาตรฐานของตัวแปรทั้งสอง

## นิยามของ Pearson's Correlation



- Pearson's correlation coefficient (Pearson's product-moment correlation coefficient) is the covariance of the two variables divided by the product of their standard deviations. (...Wikipedia)

$$\text{corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}}$$



## ข้อตกลงการใช้สูตร Pearson's Correlation

1. ตัวแปรหรือข้อมูลทั้ง 2 ชุดอยู่ในมาตรวัดชนิดอันตรภาคหรืออัตราส่วน
2. ข้อมูลทั้ง 2 ชุด มีการแจกแจงแบบปกติและมีความสัมพันธ์เชิงเส้นตรง
3. ข้อมูลในแต่ละชุดจะต้องมีความเป็นอิสระต่อกัน



## การแปรปรวนร่วม (Covariation)

- Blalock (1972): ได้ให้นิยามขององศาแห่งความสัมพันธ์เชิงเส้น (degree of linear relation) ของข้อมูลจาก ต.ย.ขนาด n ด้วยค่าของการแปรปรวนร่วม (Covariation) ดังนี้

$$Covariation = \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y}) = S_{XY}$$

เอสใหญ่

- จากหนังสือ Social statistics, 2<sup>nd</sup> ed. ของ Blalock (1972)

$$Standard\ Deviation = s_x = \sqrt{\frac{\sum (X_i - \bar{X})^2}{n - 1}}$$

$$Variance = s_x^2 = \frac{\sum (X_i - \bar{X})^2}{n - 1}$$

$$Sum\ of\ Square\ of\ X = S_X^2 (big) = \sum (X_i - \bar{X})^2$$

$$S_X (big) = \sqrt{\sum (X_i - \bar{X})^2}$$

$$Covariation = Sum\ of\ Square\ XY = S_{XY} (big) = \sum (X_i - \bar{X})(Y_i - \bar{Y})$$

$$Covariance = Cov(X, Y) = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{n - 1}$$

$$Correlation = r_{XY} = \frac{Cov(X, Y)}{s_x s_y}$$



## ความแปรปรวนร่วม (Covariance)

- ค่าความแปรปรวนร่วม (Covariance) คือค่าเฉลี่ยของ Covariation ก็คือองศาแห่งความสัมพันธ์เชิงเส้นเฉลี่ย
- ความแปรปรวนร่วมเป็นการวัดปริมาณการเปลี่ยนแปลงของสองตัวแปรว่า จะมีการเปลี่ยนแปลงตามกันมากน้อยเท่าใด
- สูตร Covariance

$$Cov(X, Y) = \frac{Covariation}{n-1} = \frac{S_{XY}}{n-1} = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{n-1}$$



## ปัญหาของความแปรปรวนร่วม

- การวัดองศาแห่งความสัมพันธ์เชิงเส้นระหว่าง X และ Y โดยใช้ค่า  $Cov(X, Y)$  มีข้อเสียคือค่าความแปรปรวนร่วมที่คำนวณได้ขึ้นกับ “หน่วย” และ “ขนาด” ของข้อมูลทำให้ไม่สะดวกในการตีความ การขึ้นกับขนาดของข้อมูลอาจจะทำให้เข้าใจได้ยากกว่าตัวแปร X และตัวแปร Y มีองศาแห่งความสัมพันธ์เชิงเส้นในระดับไหน เช่น
  - ถ้า  $X_1$  และ  $Y_1$  เป็นเลขจำนวนเต็มหลายหลัก ค่าของ  $Cov(X_1, Y_1)$  ก็จะเป็นหลายหลักด้วย
  - ถ้า  $X_2$  และ  $Y_2$  เป็นเลขทศนิยม ค่าของ  $Cov(X_2, Y_2)$  ก็จะเป็นทศนิยมด้วย
  - ทั้งๆ ที่  $X_1$  และ  $Y_1$  อาจมีองศาแห่งความสัมพันธ์เชิงเส้นใกล้เคียงกับ  $X_2$  และ  $Y_2$  แต่ค่าของ  $Cov(X_2, Y_2)$  ต่างจากค่าของ  $Cov(X_1, Y_1)$  มาก



## วิธีแก้ปัญหาคความแปรปรวนร่วม

- เพื่อขจัดปัญหาของการวัดองศาแห่งความสัมพันธ์เชิงเส้นระหว่างที่ขึ้นอยู่กับหน่วยและขนาดของข้อมูล จึงต้องทำการแปลงข้อมูลให้เป็นข้อมูลมาตรฐานซึ่งมีค่าเฉลี่ยเป็น 0 และค่าความแปรปรวนเป็น 1 ดังนี้

$$Z_{X_i} = \frac{X_i - \bar{X}}{s_x} \quad \text{โดยที่} \quad s_x = \sqrt{\frac{\sum (X_i - \bar{X})^2}{n-1}}$$

$$Z_{Y_i} = \frac{Y_i - \bar{Y}}{s_y} \quad \text{โดยที่} \quad s_y = \sqrt{\frac{\sum (Y_i - \bar{Y})^2}{n-1}}$$

- $s_x$  และ  $s_y$  (เอสเล็ก) = standard deviation
- ข้อมูลมาตรฐาน  $Z_x$  และ  $Z_y$  ไม่ขึ้นกับหน่วยและขนาดของข้อมูลเดิม



## ความแปรปรวนร่วมของข้อมูลมาตรฐาน

- การวัดองศาแห่งความสัมพันธ์เชิงเส้นตรงของข้อมูลมาตรฐาน ดังนี้

$$Cov(Z_X, Z_Y) = \frac{\sum Z_X Z_Y}{n-1} = \frac{\sum \left( \frac{X_i - \bar{X}}{s_x} \right) \left( \frac{Y_i - \bar{Y}}{s_y} \right)}{n-1} = \frac{\overset{Cov(X,Y)}{\sum (X_i - \bar{X})(Y_i - \bar{Y})}}{(n-1)s_x s_y}$$

$$Cov(Z_X, Z_Y) = \frac{Cov(X, Y)}{s_x s_y} = corr(X, Y) = corr(Z_X, Z_Y)$$

- นิยมเรียก “ความแปรปรวนร่วมของข้อมูลมาตรฐาน” ว่า “สัมประสิทธิ์สหสัมพันธ์”

## สัมประสิทธิ์สหสัมพันธ์เชิงเส้น

17



- สัมประสิทธิ์สหสัมพันธ์เชิงเส้น (Correlation coefficient)

$$\text{corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}}$$

- Population Correlation Coefficient (rho)

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sigma_x \sigma_y}$$

- Sample Correlation Coefficient

$$r_{XY} = \frac{\text{Cov}(X, Y)}{s_x s_y}$$

## สัมประสิทธิ์สหสัมพันธ์ของตัวอย่างสุ่ม

18



- สัมประสิทธิ์สหสัมพันธ์ของตัวอย่างสุ่ม (Sample Correlation Coefficient) หาได้จากสูตร

$$r_{XY} = \frac{\text{Cov}(X, Y)}{s_x s_y} = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y}) / (n - 1)}{s_x s_y}$$

เอสเล็ก

$$r_{XY} = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y}) / (n - 1)}{\sqrt{\frac{\sum (X_i - \bar{X})^2}{n - 1}} \sqrt{\frac{\sum (Y_i - \bar{Y})^2}{n - 1}}}$$

- ปรับสูตรใหม่โดยตัดค่า (n-1) ของเศษและส่วนออกจะได้เป็น

$$r_{XY} = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum (X_i - \bar{X})^2} \sqrt{\sum (Y_i - \bar{Y})^2}} = \frac{S_{XY}}{S_x S_y}$$

เอสใหญ่

## สัมประสิทธิ์สหสัมพันธ์ของตัวอย่างสุ่ม

19



- โดยเอสใหญ่  $S_{XY} = \sum (X_i - \bar{X})(Y_i - \bar{Y}) = \sum X_i Y_i - \frac{(\sum X_i)(\sum Y_i)}{n}$

$$S_X^2 = \sum (X_i - \bar{X})^2 = \sum X_i^2 - \frac{(\sum X_i)^2}{n}$$

$$S_Y^2 = \sum (Y_i - \bar{Y})^2 = \sum Y_i^2 - \frac{(\sum Y_i)^2}{n}$$

- ปัญหาการใช้สูตร  $r_{XY}$

- ถ้าใช้สูตรนี้กรณี  $\bar{X}$  และ  $\bar{Y}$  ที่เป็นเลขหารลงตัว (จำนวนเต็มหรือจุดทศนิยมรู้จบ) จะไม่มีความคลาดเคลื่อนอันเนื่องมาจากการปัดจุดทศนิยม
- ถ้าใช้สูตรนี้กรณี  $\bar{X}$  และ  $\bar{Y}$  ที่เป็นเลขหารไม่ลงตัว (จุดทศนิยมไม่รู้จบ) จะได้ค่า  $r_{xy}$  ที่ผิดพลาดได้จากปัญหาอันเนื่องมาจากการปัดจุดทศนิยม

## สัมประสิทธิ์สหสัมพันธ์ของตัวอย่างสุ่ม

20



- สูตรที่เหมาะสมในกรณี  $\bar{X}$  และ  $\bar{Y}$  หารลงตัวและหารไม่ลงตัว

$$r_{XY} = \frac{n \sum_{i=1}^n X_i Y_i - (\sum_{i=1}^n X_i)(\sum_{i=1}^n Y_i)}{\sqrt{n \sum_{i=1}^n X_i^2 - (\sum_{i=1}^n X_i)^2} \sqrt{n \sum_{i=1}^n Y_i^2 - (\sum_{i=1}^n Y_i)^2}}$$

- สูตรที่เหมาะสมในกรณี  $\bar{X}$  และ  $\bar{Y}$  หารลงตัว (สูตรจะง่ายลง)

$$r_{XY} = \frac{\sum_{i=1}^n X_i Y_i - n \bar{X} \bar{Y}}{\sqrt{\sum_{i=1}^n X_i^2 - n \bar{X}^2} \sqrt{\sum_{i=1}^n Y_i^2 - n \bar{Y}^2}}$$



## สัมประสิทธิ์สหสัมพันธ์ของประชากร

- สูตรที่เหมาะสมในกรณี  $\mu_x$  และ  $\mu_y$  **หารลงตัวและหารไม่ลงตัว**

$$\rho_{XY} = \frac{N \sum_{i=1}^N X_i Y_i - (\sum_{i=1}^N X_i)(\sum_{i=1}^N Y_i)}{\sqrt{N \sum_{i=1}^N X_i^2 - (\sum_{i=1}^N X_i)^2} \sqrt{N \sum_{i=1}^N Y_i^2 - (\sum_{i=1}^N Y_i)^2}}$$

- สูตรที่เหมาะสมในกรณี  $\mu_x$  และ  $\mu_y$  **หารลงตัว**

$$\rho_{XY} = \frac{\sum_{i=1}^N X_i Y_i - N\mu_x\mu_y}{\sqrt{\sum_{i=1}^N X_i^2 - N\mu_x^2} \sqrt{\sum_{i=1}^N Y_i^2 - N\mu_y^2}}$$



## การสรุปผลค่า $r_{xy}$

- ถ้าค่า  $r_{xy} = +1$ 
  - สรุปได้ว่าตัวแปร 2 ตัว (X, Y) มีความสัมพันธ์กันเชิงเส้นตรงอย่างสมบูรณ์ทางบวก และสามารถเขียนอยู่ในรูป  $Y_i = aX_i + b$  ได้
- ถ้าค่า  $r_{xy} = -1$ 
  - สรุปได้ว่าตัวแปร 2 ตัว (X, Y) มีความสัมพันธ์กันเชิงเส้นตรงอย่างสมบูรณ์ทางลบ และสามารถเขียนอยู่ในรูป  $Y_i = aX_i + b$  ได้
- ถ้าค่า  $r_{xy} = 0$ 
  - สรุปได้ว่าตัวแปร 2 ตัว (X, Y) ไม่มีความสัมพันธ์เชิงเส้นตรงต่อกัน (แต่ตัวแปรทั้งสองอาจมีความสัมพันธ์กันในลักษณะอื่น)



## ตัวอย่าง 1

- จงหาค่าสัมประสิทธิ์สหสัมพันธ์ของข้อมูลดังนี้

X	-2	-1	0	1	2
Y	-3	-1	1	3	5

$$r_{XY} = \frac{\sum X_i Y_i - n\bar{X}\bar{Y}}{\sqrt{\sum X_i^2 - n\bar{X}^2} \sqrt{\sum Y_i^2 - n\bar{Y}^2}}$$

$$r_{XY} = \frac{20}{\sqrt{10}\sqrt{40}} = 1$$

- สรุปว่าตัวแปรทั้งสองตัวมีความสัมพันธ์เชิงเส้นอย่างสมบูรณ์ทางบวก



## ตัวอย่าง 2

- จงหาค่าสัมประสิทธิ์สหสัมพันธ์ของข้อมูลดังนี้

X	0	-2	-4	2	4
Y	-1	0	1	-2	-3

$$r_{XY} = \frac{\sum X_i Y_i - n\bar{X}\bar{Y}}{\sqrt{\sum X_i^2 - n\bar{X}^2} \sqrt{\sum Y_i^2 - n\bar{Y}^2}}$$

$$r_{XY} = \frac{-20}{\sqrt{40}\sqrt{10}} = -1$$

- สรุปว่าตัวแปรทั้งสองตัวมีความสัมพันธ์เชิงเส้นอย่างสมบูรณ์ทางลบ

## ตัวอย่าง 3

25  
I.F.

- จงหาค่าสัมประสิทธิ์สหสัมพันธ์ของข้อมูลดังนี้

X	5	6	9	9	10
Y	9	11	0	15	1

$$r_{XY} = \frac{\sum X_i Y_i - n\bar{X}\bar{Y}}{\sqrt{\sum X_i^2 - n\bar{X}^2} \sqrt{\sum Y_i^2 - n\bar{Y}^2}}$$

$$r_{XY} = \frac{-24.8}{\sqrt{18.8}\sqrt{168.8}} = -0.44$$

- สรุปว่าตัวแปรทั้งสองตัวมีความสัมพันธ์เชิงเส้นไม่สมบูรณ์ทางลบ

## ตัวอย่าง 4

26  
I.F.

- จงหาค่าสัมประสิทธิ์สหสัมพันธ์ของข้อมูลดังนี้

X	1	2	3	4	5	6
Y	1	4	7	7	4	1

$$r_{XY} = \frac{\sum X_i Y_i - n\bar{X}\bar{Y}}{\sqrt{\sum X_i^2 - n\bar{X}^2} \sqrt{\sum Y_i^2 - n\bar{Y}^2}}$$

$$r_{XY} = \frac{0}{\sqrt{17.5}\sqrt{36}} = 0$$

- สรุปว่าตัวแปรทั้งสองตัวไม่มีความสัมพันธ์เชิงเส้น

## ตัวอย่าง 5

27  
I.F.

- จงหาค่าสัมประสิทธิ์สหสัมพันธ์ของข้อมูลดังนี้

X	0	-2	-4	2
Y	-3	0	1	2

$$r_{XY} = \frac{\sum X_i Y_i - n\bar{X}\bar{Y}}{\sqrt{\sum X_i^2 - n\bar{X}^2} \sqrt{\sum Y_i^2 - n\bar{Y}^2}}$$

$$r_{XY} = \frac{0}{\sqrt{20}\sqrt{14}} = 0$$

- สรุปว่าตัวแปรทั้งสองตัวไม่มีความสัมพันธ์เชิงเส้น

## ข้อสังเกต (การแปลงเชิงเส้น)

28  
I.F.

- ค่าสัมประสิทธิ์สหสัมพันธ์ของข้อมูลที่ผ่านการแปลงโดยการเอาค่าคงที่มาบวก หรือลบออกจากข้อมูลดิบจะมีค่าเท่าเดิม เนื่องจากการย้ายเส้นตรงเท่านั้น:

$$r_{x'y'} = r_{xy}$$

- ค่าสัมประสิทธิ์สหสัมพันธ์ของข้อมูลที่ผ่านการแปลงโดยการเอาค่าคงที่มากคูณ ข้อมูลดิบจะมีค่าเท่าเดิม เนื่องจากการขยายเส้นตรงเท่านั้น:

$$r_{x'y'} = r_{xy}$$

- ค่าสัมประสิทธิ์สหสัมพันธ์ของข้อมูลที่ผ่านการแปลงเป็นข้อมูลมาตรฐาน จะได้ค่าเท่าเดิมและเท่ากับค่าความแปรปรวนร่วมของข้อมูลมาตรฐานนั้น:  $r_{ZxZy} = r_{xy}$

- การแปลงเชิงเส้นนี้มีประโยชน์สำหรับปรับสเกลขนาดของข้อมูลเพื่อให้สะดวกในการคำนวณ

## ตัวอย่าง 6

29



- ให้เอา 2 บวกทุกค่าของ X และเอา 3 บวกทุกค่าของ Y แล้วหาค่าสัมประสิทธิ์สหสัมพันธ์ของข้อมูล

X	-2	-1	0	1	2
Y	-3	-1	1	3	5

$$r_{XY} = \frac{20}{\sqrt{10}\sqrt{40}} = 1$$

X'	0	1	2	3	4
Y'	0	2	4	6	8

$$r_{X'Y'} = \frac{20}{\sqrt{10}\sqrt{40}} = 1$$

## ตัวอย่าง 7

30



- ให้เอา 2 คูณแล้วบวก 1 ทุกค่าของ X และเอา 10 คูณแล้วลบ 4 ทุกค่าของ Y แล้วหาค่าสัมประสิทธิ์สหสัมพันธ์ของข้อมูล

X	-2	-1	0	1	2
Y	-3	-1	1	3	5

$$r_{XY} = \frac{20}{\sqrt{10}\sqrt{40}} = 1$$

X'	-3	-1	1	3	5
Y'	-34	-14	6	26	46

$$r_{X'Y'} = \frac{400}{\sqrt{40}\sqrt{4000}} = 1$$

## ตัวอย่าง 8

31



- ให้แปลงค่าของ X และ Y เป็นค่ามาตรฐาน Z แล้วหาค่าสัมประสิทธิ์สหสัมพันธ์ของข้อมูล

X	-2	-1	0	1	2
Y	-3	-1	1	3	5

$$r_{XY} = \frac{20}{\sqrt{10}\sqrt{40}} = 1$$

Zx	-1.265	-0.632	0	0.632	1.265
Zy	-1.265	-0.632	0	0.632	1.265

$$r_{ZxZy} = \frac{4}{\sqrt{4}\sqrt{4}} = 1$$

## สรุปคุณสมบัติของสัมประสิทธิ์สหสัมพันธ์จากตัวอย่างสู่

32



- $r_{xy}$  เป็นตัวเลขที่ไม่มีหน่วยและที่ไม่ขึ้นกับขนาดของข้อมูล
- $r_{xy}$  อยู่ในช่วงปิด  $[-1 \ 1]$
- การแปลงเชิงเส้นของข้อมูลดิบไม่ทำให้ค่า  $r_{xy}$  เปลี่ยนไป
- Note:  $\text{Cov}(X,Y)$  ไม่มีขอบเขตจำกัด, บอก direction ได้ ไม่นิยมใช้บอกขนาดความสัมพันธ์ (strength) เนื่องจากขึ้นกับขนาดและหน่วยของข้อมูล



## ข้อควรระวังในการตีความหมายของค่า $r$

33



- ค่าสัมประสิทธิ์สหสัมพันธ์บอกแต่เพียงองศาแห่งความสัมพันธ์เชิงเส้นเท่านั้น แต่**ไม่ได้บอกถึงความสัมพันธ์เชิงเหตุและผล**ระหว่างตัวแปรทั้งสอง
- ดังนั้นการพิจารณา  $r$  อย่างเดียวจะไม่สามารถสรุปความเป็นเหตุและผลของความสัมพันธ์เชิงเส้นได้
- การที่จะสรุป**ความเป็นเหตุและผล**ของความสัมพันธ์เชิงเส้นระหว่างตัวแปรทั้งสอง**จะต้องศึกษาจากทฤษฎี**ที่เกี่ยวข้องกับตัวแปรนั้นมาอธิบาย


## ข้อควรระวังในการตีความหมายของค่า $r$

34



- การนำค่าสัมประสิทธิ์สหสัมพันธ์ หรือความสัมพันธ์เชิงเส้นมาเกี่ยวพันกับความเป็นเหตุและผลมีข้อควรระวังดังนี้

1. ถ้ามีการศึกษาทฤษฎีที่เกี่ยวข้องกับตัวแปรอย่างละเอียด จะสามารถสรุปได้ว่า  $X$  เป็นสาเหตุของตัวแปร  $Y$  และตัวแปร  $Y$  เป็นผลจากตัวแปร  $X$  นอกจากนี้ ตัวแปร  $X$  จะมีความสัมพันธ์เชิงเส้นกับตัวแปร  $Y$  ด้วย แต่หากไม่มีการศึกษาทฤษฎีที่เกี่ยวข้องกับตัวแปรอย่างละเอียด จะสรุปได้เพียงความสัมพันธ์เชิงเส้นของ 2 ตัวแปรเท่านั้น




## ข้อควรระวังในการตีความหมายของค่า $r$

35



2. ในกรณีค่า  $r_{xy}$  สูง แต่เมื่อศึกษาทฤษฎีที่เกี่ยวข้องกับตัวแปร  $X$  และตัวแปร  $Y$  แล้วปรากฏว่า มีตัวแปรสอดแทรก ที่ทำให้พบความสัมพันธ์ระหว่างตัวแปร  $X$  และ  $Y$  (intervening relationship) กรณีนี้ตัวแปร  $X$  ไม่ใช่สาเหตุโดยตรงของตัวแปร  $Y$  แต่ส่งผ่านตัวแปรอื่นคือตัวแปรสอดแทรก กล่าวคือถ้าไม่มีตัวแปร  $A$  แล้วตัวแปร  $X$  และ  $Y$  จะไม่มีความสัมพันธ์เชิงเส้นต่อกันเลย




## ข้อควรระวังในการตีความหมายของค่า $r$

36



3. ในกรณีค่า  $r_{xy}$  สูง แต่เมื่อศึกษาทฤษฎีที่เกี่ยวข้องกับตัวแปร  $X$  และตัวแปร  $Y$  แล้วปรากฏว่า ตัวแปร  $X$  ไม่ใช่สาเหตุของตัวแปร  $Y$  กรณีนี้เรียกว่า ความสัมพันธ์สูง (spurious relationship) กล่าวคือจริงๆ แล้วตัวแปรทั้งสองไม่มีความสัมพันธ์เชิงเส้นต่อกัน



## การทดสอบสมมติฐานค่าสัมประสิทธิ์สหสัมพันธ์ 37

- ค่าสัมประสิทธิ์สหสัมพันธ์ใช้วัดองศาแห่งความสัมพันธ์เชิงเส้น การสรุปว่าตัวแปร 2 ตัวมีความสัมพันธ์เชิงเส้นกันหรือไม่ จะต้องผ่านการทดสอบสมมติฐาน

$H_0 : \rho = 0$  (ไม่มีความสัมพันธ์เชิงเส้น)

$H_1 : \rho \neq 0$  (มีความสัมพันธ์เชิงเส้น)

- ค่าสถิติที่ใช้ทดสอบสมมติฐานมี 3 ตัวคือ

- ค่าสถิติ r
- ค่าสถิติ t
- ค่าสถิติ z

Hypothesized  
Population  
Correlation ( $\rho_0$ )

- ค่าสถิติ r และ t ใช้ทดสอบสมมติฐานกรณี  $H_0 : \rho = 0$  เท่านั้นหาก กรณี  $\rho \neq 0$  เช่น  $H_0 : \rho = 0.5$  ต้องใช้สถิติ z

## การทดสอบสมมติฐานค่าสัมประสิทธิ์สหสัมพันธ์ 38

- ค่าสถิติ r

$$r_{XY} = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum (X_i - \bar{X})^2} \sqrt{\sum (Y_i - \bar{Y})^2}} = \frac{S_{XY}}{S_X S_Y} \quad df = n-2$$

- ปฏิเสธ  $H_0$  ที่ระดับนัยสำคัญ  $\alpha\%$  ก็ต่อเมื่อ  $|r| \geq r_{[\alpha, n-2]}$

- โดยที่  $\alpha$  คือระดับนัยสำคัญ  
n คือขนาดตัวอย่างสุ่ม

เนื่องจากในตารางให้  
มาเป็นตาราง 2-tail

## การทดสอบสมมติฐานค่าสัมประสิทธิ์สหสัมพันธ์ 39

- ค่าสถิติ t

$$t = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}} \quad df = n-2$$

- โดยที่ r คือค่า สปส.สหสัมพันธ์จากตัวอย่างสุ่ม

n คือขนาดตัวอย่างสุ่ม

- ปฏิเสธ  $H_0$  ที่ระดับนัยสำคัญ  $\alpha\%$  ก็ต่อเมื่อ  $|t| \geq t_{[\alpha/2, n-2]}$

## การทดสอบสมมติฐานค่าสัมประสิทธิ์สหสัมพันธ์ 40

- ค่าสถิติ z

$$Z = \frac{Z_r - Z_\rho}{\sigma_{Z_r}}$$

- โดยที่

$$Z_r = \frac{1}{2} [\ln(1+r) - \ln(1-r)]$$

$$Z_\rho = \frac{1}{2} [\ln(1+\rho) - \ln(1-\rho)] \rightarrow \text{ค่า } Z_\rho = 0 \text{ กรณี } \rho_0 = 0$$

$$\sigma_{Z_r} = \frac{1}{\sqrt{n-3}}$$

- ปฏิเสธ  $H_0$  ที่ระดับนัยสำคัญ  $\alpha\%$  ก็ต่อเมื่อ  $|z| \geq z_{[\alpha/2]}$

## ตัวอย่าง 9

- จากข้อมูลดังนี้ ได้ค่า  $r = -0.44$  จงทดสอบสมมติฐานว่าตัวแปร X และตัวแปร Y มีความสัมพันธ์เชิงเส้นหรือไม่ ที่ระดับนัยสำคัญ 0.05 (5%)

X	5	6	9	9	10
Y	9	11	0	15	1

$$H_0 : \rho = 0$$

$$H_1 : \rho \neq 0$$

## ตัวอย่าง 9

- กรณีใช้ค่าสถิติ r ทดสอบ

$$r = \frac{S_{XY}}{S_X S_Y} = -0.44$$

- จากตารางสถิติ  $r_{[0.05,3]} = 0.878$  (ตาราง 2-tail) =  $r_{[0.025,3]}$  (1-tail)
- พบว่า  $|r| < r_{[0.05,3]}$
- สรุปว่า ไม่ปฏิเสธ  $H_0$  ที่  $\alpha=0.05$
- แปลว่า จากข้อมูลที่ได้จาก ต.ย.ขนาด 5 อนุมานได้ว่า ตัวแปรทั้งสองตัวไม่มีความสัมพันธ์เชิงเส้น

## การเปิดตารางหาค่า r

- $r_{0.025,3}(1\text{-tail}) = r_{0.05,3}(2\text{-tail})$

Critical Values for Pearson's Correlation Coefficient						
DF	Proportion in ONE Tail					
	.25	.10	.05	.025	.01	.005
Proportion in TWO Tails						
	.50	.20	.10	.05	.02	.01
1	.7071	.9511	.9877	.9969	.9995	.9999
2	.5000	.8000	.9000	.9500	.9800	.9900
3	.4040	.6870	.8054	.8783	.9343	.9587
4	.3473	.6084	.7293	.8114	.8822	.9172
5	.3091	.5509	.6694	.7545	.8329	.8745
6	.2811	.5067	.6215	.7067	.7887	.8343
7	.2596	.4716	.5822	.6664	.7498	.7977
8	.2423	.4428	.5494	.6319	.7155	.7646
9	.2281	.4187	.5214	.6021	.6851	.7348
10	.2161	.3981	.4973	.5760	.6581	.7079

## ตัวอย่าง 9

- กรณีใช้ค่าสถิติ t ทดสอบ

$$t = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}} = \frac{-0.44\sqrt{5-2}}{\sqrt{1-(-0.44)^2}} = -0.849$$

- จากตารางสถิติ  $t_{[0.025,3]} = -3.182$
- พบว่า  $|t| < t_{[0.025,3]}$
- สรุปว่า ไม่ปฏิเสธ  $H_0$  ที่  $\alpha=0.05$
- แปลว่า จากข้อมูลที่ได้จาก ต.ย.ขนาด 5 อนุมานได้ว่า ตัวแปรทั้งสองตัวไม่มีความสัมพันธ์เชิงเส้น

## ตัวอย่าง 9



- กรณีใช้ค่าสถิติ  $z$  ทดสอบ:  $Z_p=0$  ,  $\sigma_{z_r} = \frac{1}{\sqrt{n-3}} = \frac{1}{\sqrt{5-3}} = 0.7071$   

$$Z_r = \frac{1}{2} [\ln(1+r) - \ln(1-r)] = \frac{1}{2} [\ln(1-0.44) - \ln(1+0.44)] = -0.472$$

$$Z = \frac{Z_r - Z_p}{\sigma_{z_r}} = \frac{-0.472 - 0}{0.7071} = -0.6675$$
- จากตารางสถิติ  $z_{[0.025]} = -1.96$
- พบว่า  $|z| < z_{[0.025]}$
- สรุปว่า ไม่ปฏิเสธ  $H_0$  ที่  $\alpha=0.05$
- แปลว่า จากข้อมูลที่ได้จาก ต.ย.ขนาด 5 อนุมานได้ว่า ตัวแปรทั้งสองตัวไม่มีความสัมพันธ์เชิงเส้น

## ตัวอย่าง 10



- จากข้อมูลตัวอย่างสุ่มขนาด 103 มีค่า  $r = -0.67$  จงทดสอบสมมติฐานว่า ตัวแปร  $X$  และตัวแปร  $Y$  มีความสัมพันธ์เชิงเส้นในทางลบหรือไม่ ที่ระดับนัยสำคัญ 0.01 (1%)

$$H_0 : \rho = 0$$

$$H_1 : \rho < 0$$

## ตัวอย่าง 10



- กรณีใช้ค่าสถิติ  $r$  ทดสอบ
- $$r = \frac{S_{XY}}{S_X S_Y} = -0.67$$
- จากตารางสถิติ  $r_{[0.02,101]} = 0.230$  (ตาราง 2-tail) =  $r_{[0.01,101]}$  (1-tail)
- พบว่า  $|r| \geq r_{[0.02,101]}$
- สรุปว่า ปฏิเสธ  $H_0$  ที่  $\alpha=0.01$
- แปลว่า จากข้อมูลที่ได้จาก ต.ย.ขนาด 103 อนุมานได้ว่า ตัวแปรทั้งสองตัวมีความสัมพันธ์เชิงเส้นในทางลบ

## ตัวอย่าง 10



- กรณีใช้ค่าสถิติ  $t$  ทดสอบ

$$t = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}} = \frac{-0.67\sqrt{103-2}}{\sqrt{1-(-0.67)^2}} = -9.070$$

- จากตารางสถิติ  $t_{[0.01,101]} = -2.3638$  (ตาราง 1-tail) =  $t_{[0.02,101]}$  (2-tail)
- พบว่า  $|t| \geq t_{[0.01,101]}$
- สรุปว่า ปฏิเสธ  $H_0$  ที่  $\alpha=0.01$
- แปลว่า จากข้อมูลที่ได้จาก ต.ย.ขนาด 103 อนุมานได้ว่า ตัวแปรทั้งสองตัวมีความสัมพันธ์เชิงเส้นในทางลบ

## ตัวอย่าง 10

49



- กรณีใช้ค่าสถิติ  $z$  ทดสอบ:  $Z_p=0$  ,  $\sigma_{z_r} = \frac{1}{\sqrt{n-3}} = \frac{1}{\sqrt{103-3}} = 0.1$   

$$Z_r = \frac{1}{2} [\ln(1+r) - \ln(1-r)] = \frac{1}{2} [\ln(1-0.67) - \ln(1+0.67)] = -0.811$$

$$Z = \frac{Z_r - Z_p}{\sigma_{z_r}} = \frac{-0.811 - 0}{0.1} = -8.11$$
- จากตารางสถิติ  $z_{[0.01]} = -2.326$
- พบว่า  $|z| \geq z_{[0.01]}$
- สรุปว่า ปฏิเสธ  $H_0$  ที่  $\alpha=0.01$
- แปลว่า จากข้อมูลที่ได้จาก ต.ย.ขนาด 103 อนุมานได้ว่า ตัวแปรทั้งสองตัวมีความสัมพันธ์เชิงเส้นในทางลบ

## ตัวอย่าง 11

50



- จากข้อมูลตัวอย่างสุ่มขนาด 50 มีค่า  $r = 0.889$  จงทดสอบสมมติฐานว่า ตัวแปร  $X$  และตัวแปร  $Y$  มีความสัมพันธ์เชิงเส้นในทางบวกหรือไม่ ที่ระดับนัยสำคัญ 0.01 (1%)

$$H_0 : \rho = 0$$

$$H_1 : \rho > 0$$

## ตัวอย่าง 11

51



- กรณีใช้ค่าสถิติ  $r$  ทดสอบ

$$r = \frac{S_{XY}}{S_X S_Y} = 0.889$$

- จากตารางสถิติ  $r_{[0.02,48]} = 0.328$  (ตาราง 2-tail)
- พบว่า  $|r| \geq r_{[0.02,101]}$
- สรุปว่า ปฏิเสธ  $H_0$  ที่  $\alpha=0.01$
- แปลว่า จากข้อมูลที่ได้จาก ต.ย.ขนาด 50 อนุมานได้ว่า ตัวแปรทั้งสองตัวมีความสัมพันธ์เชิงเส้นในทางบวก

## ตัวอย่าง 11

52



- กรณีใช้ค่าสถิติ  $t$  ทดสอบ

$$t = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}} = \frac{0.889\sqrt{50-2}}{\sqrt{1-(0.889)^2}} = 13.45$$

- จากตารางสถิติ  $t_{[0.01,48]} = 2.4066$  (ตาราง 1-tail)
- พบว่า  $|t| \geq t_{[0.01,48]}$
- สรุปว่า ปฏิเสธ  $H_0$  ที่  $\alpha=0.01$
- แปลว่า จากข้อมูลที่ได้จาก ต.ย.ขนาด 50 อนุมานได้ว่า ตัวแปรทั้งสองตัวมีความสัมพันธ์เชิงเส้นในทาง**บวก**

## ตัวอย่าง 11



- กรณีใช้ค่าสถิติ  $z$  ทดสอบ:  $Z_p=0$  ,  $\sigma_{z_r} = \frac{1}{\sqrt{n-3}} = \frac{1}{\sqrt{50-3}} = 0.1459$

$$Z_r = \frac{1}{2} [\ln(1+r) - \ln(1-r)] = \frac{1}{2} [\ln(1+0.889) - \ln(1-0.889)] = 1.417$$

$$Z = \frac{Z_r - Z_p}{\sigma_{z_r}} = \frac{1.417 - 0}{0.1459} = 9.712$$

- จากตารางสถิติ  $z_{[0.01]} = 2.326$
- พบว่า  $|z| \geq z_{[0.01]}$
- สรุปว่า ปฏิเสธ  $H_0$  ที่  $\alpha=0.01$
- แปลว่า จากข้อมูลที่ได้จาก ต.ย.ขนาด 50 อนุมานได้ว่า ตัวแปรทั้งสองตัวมีความสัมพันธ์เชิงเส้นในทางบวก



## คำถาม